『寝ながら学べる因果推論』オンライン付録

4　第 4 章に対応する補足資料

4.1　回帰係数の正体

ここでは，条件付き期待値と線形回帰の数学的な関係を説明します．

本文で見たように，$\mathbb{E}[Y \mid X = x]$ は「$X = x$ という条件のもとで Y を最もよく説明する値」です．では，Y 全体を $\mathbb{E}[Y \mid X]$ で説明したとき，説明しきれない部分はどうなるでしょうか？

Y から $\mathbb{E}[Y \mid X]$ を引いた残差を

$$\varepsilon = Y - \mathbb{E}[Y \mid X]$$

と定義すると，

$$Y = \mathbb{E}[Y \mid X] + \varepsilon, \qquad \mathbb{E}[\varepsilon \mid X] = 0$$

と表せます．この分解と残差の性質を **CEF 分解定理**といいます（Angrist and Pischke 2009）．残差 ε は「X の情報だけでは説明できない Y の変動」を表しています．

一般には，$\mathbb{E}[Y \mid X = x]$ の具体的な関数形は未知で，複雑な非線形関数かもしれません．そこで，Y を X の線形関数

$$\alpha + \beta X$$

で近似することを考えます．Y とこの線形関数との差を U と書けば，

$$Y = \alpha + \beta X + U$$

と分解できます．このときパラメータ α, β を

$$\mathbb{E}[(Y - a - bX)^2]$$

が最小になるように選ぶ方法を**線形射影**（linear projection）といいます．

線形射影の定義（$\mathbb{E}[(Y-a-bX)^2]$ の最小化）の 1 階条件として，残差 $U = Y - \alpha - \beta X$ は次の**直交条件**を自動的に満たします：

$$\begin{aligned}\mathbb{E}[U] &= 0,\\ \mathbb{E}[XU] &= 0\end{aligned}$$

この二つの条件に $U = Y - \alpha - \beta X$ を代入して整理すると

$$\begin{aligned}\mathbb{E}[Y - \alpha - \beta X] &= 0,\\ \mathbb{E}[X(Y - \alpha - \beta X)] &= 0\end{aligned}$$

となり，期待値の線形性を使って変形すると

$$\begin{aligned}\alpha &= \mathbb{E}[Y] - \beta\mathbb{E}[X],\\ \beta &= \frac{\mathrm{Cov}(X,Y)}{V(X)}\end{aligned}$$

が得られます.

$\mathbb{E}[U \mid X] = 0$（**外生性**）はこれより強い条件です．線形射影の残差は

$$U = \varepsilon + (\mathbb{E}[Y \mid X] - \alpha - \beta X)$$

と書けるため,

$$\mathbb{E}[U \mid X] = \mathbb{E}[Y \mid X] - \alpha - \beta X$$

となります．これがゼロになるのは，CEF がちょうど線形（$\mathbb{E}[Y \mid X] = \alpha + \beta X$）のときに限ります.

なお，X と Y の標本 (X_i, Y_i)（$i = 1, 2, \ldots, n$）を使ってパラメータ α, β を推定する場合は

$$\begin{aligned}\hat{\alpha} &= \bar{Y} - \hat{\beta}\bar{X},\\ \hat{\beta} &= \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_i (X_i - \bar{X})^2}\end{aligned}$$

を用います.

この推定量は，線形回帰モデル $\hat{Y} = a + bX$ で Y を予測したときの誤差の二乗和が最小になる係数 a, b の計算法と同じです．上記の推定量を**最小二乗推定量**（OLS estimator: ordinary least squares estimator）と呼びます.

4.2　シンプソンのパラドクスが生じる仕組み

本文第 4 章の紙とペンが必要なポイントで，次の問いを出しました．性別で層別すれば薬の効果は男女ともに正なのに，全体集計では逆転するのはなぜか．ここでは繰り返し期待値の法則を使って，その仕組みを説明します．数値は本文の表と同じです．

表 1　男女別の薬の効果（本文第 4 章の再掲）

	薬あり $(D=1)$		薬なし $(D=0)$	
	人数	回復率	人数	回復率
男性 $(W=\text{男})$	100 人	90.0%	300 人	86.7%
女性 $(W=\text{女})$	300 人	70.0%	100 人	60.0%
合計	400 人	75.0%	400 人	80.0%

はじめに，処置群と統制群それぞれの平均を，性別の層に分解します．繰り返し期待値の法則を処置群（$D=1$）の中だけに適用する，すなわち「$D=1$ という条件のもとで，さらに W で条件づけてから W について平均する」と考えます．

$$\mathbb{E}[Y \mid D=1] = \sum_{w} \mathbb{E}[Y \mid D=1, W=w]\, P(W=w \mid D=1),$$
$$\mathbb{E}[Y \mid D=0] = \sum_{w} \mathbb{E}[Y \mid D=0, W=w]\, P(W=w \mid D=0)$$

表 1 を当てはめると，処置群の男女比は $P(W=\text{男} \mid D=1) = 1/4$，$P(W=\text{女} \mid D=1) = 3/4$ ですから

$$\mathbb{E}[Y \mid D=1] = 0.900 \times \frac{1}{4} + 0.700 \times \frac{3}{4} = 0.750,$$
$$\mathbb{E}[Y \mid D=0] = 0.867 \times \frac{3}{4} + 0.600 \times \frac{1}{4} = 0.800$$

となり，観察された差は $0.750 - 0.800 = -0.050$ です．

ここで二つの式を見比べると，層ごとの回復率にかける重みが処置群と統制群で違っています．処置群は女性が $3/4$ を占め，統制群は男性が $3/4$ を占めているからです．女性は男性より回復率が低いので，処置群だけが回復しにくい人の多い集団になっています．つまり観察された差は，薬そのものの効果である層内の差と，比較する二つの集団の構成

の違いである重みの差が混ざった量です．層内の差が男女とも正であっても，後者が十分に大きければ全体では符号が逆転します．

薬の効果だけを取り出すには，両群に共通の重み，すなわち母集団での男女比 $P(W = w)$ を使って層内の差を平均します．これが共変量調整の計算にあたり，層ごとの平均を足し戻すときに繰り返し期待値の法則を使います．ただし，この計算結果を因果効果と解釈するには，条件付き独立，一致性，正値性などの条件が必要です．

$$\mathrm{ATE} = \sum_{w} \big\{ \mathbb{E}[Y \mid D = 1, W = w] - \mathbb{E}[Y \mid D = 0, W = w] \big\} P(W = w)$$

母集団は男性 400 人・女性 400 人なので $P(W = \text{男}) = P(W = \text{女}) = 1/2$ です．層内の差は男性が $0.900 - 0.867 = 0.033$，女性が $0.700 - 0.600 = 0.100$ ですから

$$\mathrm{ATE} = 0.033 \times \frac{1}{2} + 0.100 \times \frac{1}{2} = 0.067$$

となり，薬の効果は約 $+6.7\%$ と正の値になります．観察された -5.0% との差 -11.7% が，構成の偏りによって生じた見かけの分です．

繰り返し期待値の法則は，層ごとの平均を重みで足し戻す操作でした．シンプソンのパラドクスは，この重みを群ごとに変えてしまうことから生じます．処置群と統制群で共変量の分布が違うまま平均すると，層内で一貫して成立する関係が全体で逆転しうるのです．どちらの群にも同じ重み $P(W = w)$ を使えば，層内の差の平均として ATE が得られます．この操作が正当化される条件については付録 6.1 を，どの変数で調整すべきかという判断については本文第 7 章を参照してください．

4.3　クロス表からの OLS 係数の計算

本文では，次のクロス表を使って回帰係数を求めました．ここではその計算過程を示します．

		Y		
		0（治らない）	1（治る）	合計
X	0（飲まない）	40	10	50
	1（飲む）	10	40	50
	合計	50	50	100

X と Y はいずれも，100 人中 50 人が 0，50 人が 1 なので，平均は $\bar{X} = \bar{Y} = 0.5$ です．S_{xy} は，クロス表の各セルについて，X と Y の平均からのずれの積に人数を掛け，それ

らを合計して求めます．したがって，

$$\begin{aligned} S_{xy} &= 40(0-0.5)(0-0.5) + 10(0-0.5)(1-0.5) \\ &\quad + 10(1-0.5)(0-0.5) + 40(1-0.5)(1-0.5) \\ &= 40(0.25) + 10(-0.25) + 10(-0.25) + 40(0.25) \\ &= 15 \end{aligned}$$

です．一方，S_{xx} は X の平均からのずれの二乗和です．$X=0$ の人と $X=1$ の人がそれぞれ 50 人なので，

$$\begin{aligned} S_{xx} &= 50(0-0.5)^2 + 50(1-0.5)^2 \\ &= 50(0.25) + 50(0.25) \\ &= 25 \end{aligned}$$

となります．よって，OLS 係数は

$$\hat{\beta} = \frac{S_{xy}}{S_{xx}} = \frac{15}{25} = 0.6$$

です．

5　第 5 章に対応する補足資料

5.1　回帰で ATE が推定できる理由

観測結果 Y を処置変数 D に回帰すると，なぜ平均処置効果の推定値が得られるのでしょうか？その理由を潜在的結果モデルから確認します．一致性の仮定より，

$$Y_i = D_i Y_i(1) + (1-D_i)Y_i(0) = Y_i(0) + (Y_i(1) - Y_i(0))D_i$$

と書けます．ここで

$$\begin{aligned} \alpha &= \mathbb{E}[Y_i(0)], \\ \beta &= \mathbb{E}[Y_i(1) - Y_i(0)] \end{aligned}$$

と定義します．β は平均処置効果（ATE）です．上の式に $\mathbb{E}[Y_i(0)]$ と $\mathbb{E}[Y_i(1)-Y_i(0)]D_i$ を足して引くと，

$$Y_i = \alpha + \beta D_i + U_i$$

と表せます．ただし，誤差項 U_i は

$$U_i = Y_i(0) - \mathbb{E}[Y_i(0)] + \big(Y_i(1) - Y_i(0) - \mathbb{E}[Y_i(1) - Y_i(0)]\big)D_i$$

です.

この式はデータの生成過程を表す構造的因果モデルではありません．ランダム割当により，後で示す $\mathbb{E}[U_i \mid D_i] = 0$ が成り立つとき，この式の α, β は

$$(\alpha, \beta) = \arg\min_{a,b} \mathbb{E}[(Y - a - bD)^2]$$

を満たす線形射影の係数にも一致します．線形射影については前節「回帰係数の正体」を参照してください．また，D が二値であるため，この回帰モデルは $\mathbb{E}[Y \mid D]$ と完全に一致します.

ただし，回帰モデルそれ自体が因果メカニズムを表すものではありません．回帰係数を因果効果として解釈するためには，処置のランダム割当などの識別条件が必要です.

この線形射影の係数 β が平均処置効果と一致するのはどのようなときかを確かめます．$D_i = 1$ のとき，

$$\begin{aligned}\mathbb{E}[Y_i \mid D_i = 1] &= \mathbb{E}[\alpha + \beta D_i + U_i \mid D_i = 1] \\ &= \alpha + \beta + \mathbb{E}[U_i \mid D_i = 1]\end{aligned}$$

です．一方，$D_i = 0$ のとき，

$$\begin{aligned}\mathbb{E}[Y_i \mid D_i = 0] &= \mathbb{E}[\alpha + \beta D_i + U_i \mid D_i = 0] \\ &= \alpha + \mathbb{E}[U_i \mid D_i = 0]\end{aligned}$$

です．したがって，

$$\mathbb{E}[Y_i \mid D_i = 1] - \mathbb{E}[Y_i \mid D_i = 0] = \beta + \big(\mathbb{E}[U_i \mid D_i = 1] - \mathbb{E}[U_i \mid D_i = 0]\big)$$

となります.

処置 D をランダムに割り当てると，

$$D_i \perp (Y_i(0), Y_i(1))$$

が成立します．この独立性と誤差項の定義から，

$$\mathbb{E}[U_i \mid D_i = 0] = \mathbb{E}[U_i \mid D_i = 1] = 0$$

となります．よって，

$$\mathbb{E}[Y_i \mid D_i = 1] - \mathbb{E}[Y_i \mid D_i = 0] = \beta$$

であり，回帰係数 β と平均処置効果が一致します[*1].

[*1] Angrist and Pischke (2009) の説明を，個体ごとの処置効果が異なる場合も許す形に再構成しています.

一般に，

$$\mathbb{E}[U_i \mid D_i = 1] - \mathbb{E}[U_i \mid D_i = 0]$$

をセレクションバイアスと呼びます．これは，潜在的結果に含まれる個体差が処置割当と関連しているために生じるバイアスです．ランダム割当ではこの項がゼロになるため，観測結果の平均差を平均処置効果として解釈できます．

5.2　潜在的結果を確率変数として扱う場合

本文第 5 章では，対象を有限母集団とし，各個体の潜在的結果 $Y_i(0), Y_i(1)$ を固定値として扱いました．ここでは，単に母集団から個体をランダムに抽出するモデルを考えます．このモデルでは，潜在的結果も確率変数です[*2]．イメージを図 1 に示します．

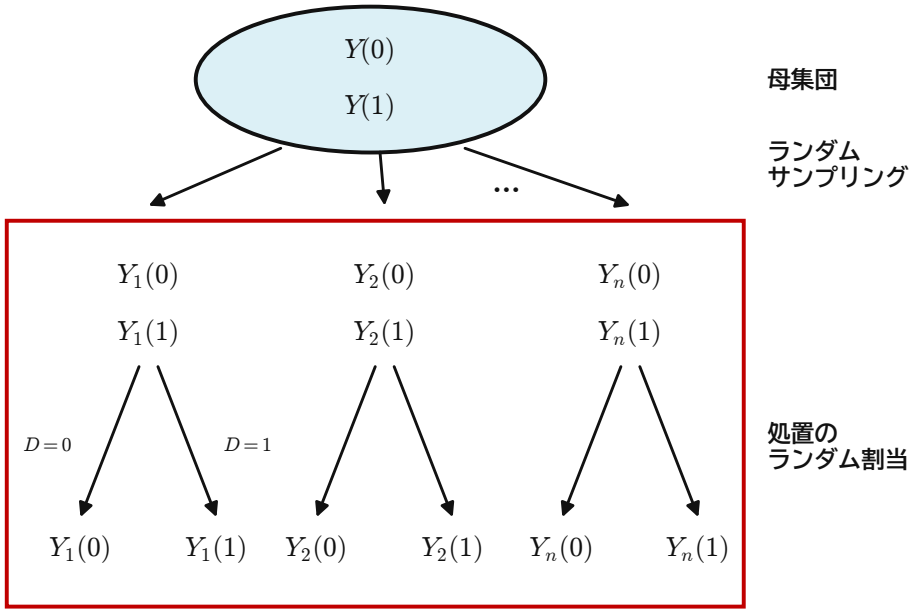


図 1　ランダムサンプリングとランダム割当て

個体 i の潜在的結果の組を $(Y_i(0), Y_i(1))$ とします．母集団から n 人をランダムに抽出するとき，

$$(Y_1(0), Y_1(1)), \ldots, (Y_n(0), Y_n(1))$$

[*2] たとえば Rosenbaum and Rubin (1983) では，対象となる個体を母集団からのランダムサンプルとして扱っています．潜在的結果を固定値とするか確率変数とするかは，モデルの仮定に依存します．

が個体 i について独立同分布に従うと仮定します．これは，異なる個体の潜在的結果の組が互いに独立で，すべて同じ母集団分布に従うという意味です．同じ個体内の $Y_i(0)$ と $Y_i(1)$ が互いに独立である必要はありません．

独立同分布の仮定により，任意の i について

$$\mathbb{E}[Y_i(0)] = \mu_0, \qquad \mathbb{E}[Y_i(1)] = \mu_1$$

が成立します．母集団における平均処置効果は

$$\tau = \mu_1 - \mu_0$$

です．

この設定のもとで，平均値の差による推定量が不偏になることを確かめます．抽出した n 人のうち n_1 人を処置群，$n_0 = n - n_1$ 人を統制群へランダムに割り当てるとします．平均値の差による推定量は

$$\hat{\tau} = \frac{1}{n_1}\sum_{i=1}^{n} D_i Y_i(1) - \frac{1}{n_0}\sum_{i=1}^{n}(1 - D_i)Y_i(0)$$

です．固定人数をランダムに割り当てると，各個体が処置群に入る確率は n_1/n なので，$\mathbb{E}_D[D_i] = n_1/n$ です．したがって，抽出された潜在的結果を固定したうえで処置割当について期待値をとると，

$$\mathbb{E}_D[\hat{\tau} \mid \{Y_i(0), Y_i(1)\}_{i=1}^n] = \frac{1}{n}\sum_{i=1}^{n} Y_i(1) - \frac{1}{n}\sum_{i=1}^{n} Y_i(0)$$

となります．さらにランダムサンプリングについて期待値をとれば，

$$\begin{aligned}\mathbb{E}_Y[\mathbb{E}_D[\hat{\tau} \mid \{Y_i(0), Y_i(1)\}_{i=1}^n]] &= \mathbb{E}[Y_i(1)] - \mathbb{E}[Y_i(0)] \\ &= \mu_1 - \mu_0 \\ &= \tau\end{aligned}$$

です．したがって，潜在的結果を確率変数として扱う場合にも，平均値の差は母集団の平均処置効果の不偏推定量になります．

ここまで前提にしてきた独立同分布（i.i.d.）という言葉の意味を確認しておきます．母集団と標本の定義にはいくつかの流儀があります．ここでは，母集団からの無作為抽出として標本を捉えるモデルを確認します．

みなさんは忍者漫画に登場する「分身の術」をご存じでしょうか？分身の術は術者本人と全く同じコピーを作り出し，相手を幻惑させる技です．生み出された分身が本体と同

じ，というイメージが独立同分布を理解するときに役立ちます．独立同分布とはいわば，本体である母集団分布 F から生み出された分身 $X_1, X_2, \ldots, X_n$ のことを指します．本体と同じ，という点がポイントです．

分身の術で生み出された分身たちは，本体と同じ能力を持ちます（同分布）．ただし，それぞれの分身は互いに無関係に動きます（独立）．この様子を図 2 に示します．

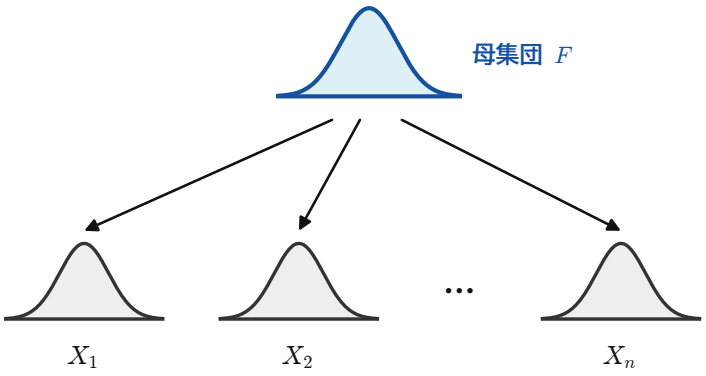


図 2　分身の術と独立同分布のイメージ．母集団分布 F から生み出された $X_1, X_2, \ldots, X_n$ は，どれも本体と同じ形の分布をもつ

スタンダードな現代数理統計学では，母集団と標本を次のように定義します．たとえば，10 歳の男児の身長が興味の対象であるとします．このとき，10 歳の男児全体を母集団と考えます．いま，すべての 10 歳の男児の身長を 1 枚ずつカードに記入し，箱に入れてよくかき混ぜ，そこからカードを取り出す状況を考えます（竹村 2020）．

箱の中のカードの枚数を母集団の大きさといい，N で表します．1 人の身長が 1 枚のカードに書かれているので，N は 10 歳の男児の総数と一致します．箱から取り出したカードの枚数を n とおき，これを標本の大きさと呼びます．

箱の中にあるすべてのカードに書かれた身長を $a_1, a_2, \ldots, a_N$ とおきます．$a_1, a_2, \ldots, a_N$ の分布を**母集団分布**といいます．

次に，取り出したカードに書かれた値を確率変数 $X_1, X_2, \ldots, X_n$ で表します．ここでカードは一度取り出したら箱に戻し，再び次の 1 枚を取り出すと仮定します．カードを取り出すたびに，箱の中の状態が「復元」されるので，このような取り出し方を「復元抽出」といいます．復元抽出を仮定すると，$X_1, X_2, \ldots, X_n$ は互いに独立な確率変数になります．

ここで重要なのは，「取り出したカードを確率変数 $X_1, X_2, \ldots, X_n$ で表す」とした点で

す．X_1 や X_2 は確率変数であり，それぞれが分布を持ちます．実際に観測された標本の一つは，たとえば 120cm という具体的な数値です．一方，数学モデル上の X_1 は確率変数であり，母集団に含まれるどの値も取り得ます．

実際に確かめてみましょう．$a_1, a_2, \ldots, a_N$ がすべて異なる値であれば，

$$P(X_i = a_j) = \frac{1}{N}, \qquad j = 1, 2, \ldots, N$$

が成り立ちます．このとき，$X_1, X_2, \ldots, X_n$ の分布はすべて同一であり，各 a_j を同様に確からしく確率 $1/N$ でとります．$a_1, a_2, \ldots, a_N$ に同じ値が含まれる場合でも，X_i の累積分布関数は母集団の累積分布関数と一致します．

したがって，母集団とは「そこから一つの観測値 X_1 を無作為に取り出したときの分布」であるともいえます．すべてのカードを同じ確率で取り出す方法を単純無作為抽出といいます．現実には，箱の中のカードをよく混ぜてから取り出す操作がこれに対応します．$N \to \infty$ とする極限では，母集団を無限母集団と呼びます．

まとめると，母集団から復元単純無作為抽出によって大きさ n の標本を得ることは，数学的にはある確率分布 F から互いに独立な n 個の確率変数 $X_1, X_2, \ldots, X_n$ を観測することに等しいのです．このとき

$$X_1, X_2, \ldots, X_n \sim F, \qquad \text{i.i.d.}$$

と表し，これらは独立同分布に従うといいます．i.i.d. は independent and identically distributed の略です．

6　第 6 章に対応する補足資料

6.1　共変量の調整が機能する理由

なぜ，共変量でデータを層別し，各層で計算した処置群と統制群の平均結果の差を共変量の分布で平均すると，全体の ATE を識別できるのでしょうか？ここでは，共変量による条件付き独立 $(Y(0), Y(1)) \perp D \mid X$，一致性 $Y = DY(1) + (1 - D)Y(0)$，そしてすべての共変量層 x について $0 < P(D = 1 \mid X = x) < 1$ が成り立つという条件付き正値性の三つを仮定します．

まず，共変量の値 x ごとに処置群と統制群の平均結果の差

$$\mathbb{E}[Y \mid D = 1, X = x] - \mathbb{E}[Y \mid D = 0, X = x]$$

を考えます．一致性により，この式は

$$\mathbb{E}[Y(1) \mid D=1, X=x] - \mathbb{E}[Y(0) \mid D=0, X=x]$$

と書き換えられます．さらに，共変量による条件付き独立から

$$\begin{aligned}\mathbb{E}[Y(1) \mid D=1, X=x] &= \mathbb{E}[Y(1) \mid X=x],\\ \mathbb{E}[Y(0) \mid D=0, X=x] &= \mathbb{E}[Y(0) \mid X=x]\end{aligned}$$

が成立します．したがって，各層の観測結果の平均差は

$$\mathbb{E}[Y(1) \mid X=x] - \mathbb{E}[Y(0) \mid X=x]$$

に一致します．条件付き正値性は，どの共変量層でもこの二群を比較できることを保証します．

この差を共変量 X の分布で平均すると，

$$\begin{aligned}&\sum_x \big\{\mathbb{E}[Y \mid D=1, X=x] - \mathbb{E}[Y \mid D=0, X=x]\big\} P(X=x)\\ &= \sum_x \big\{\mathbb{E}[Y(1) \mid X=x] - \mathbb{E}[Y(0) \mid X=x]\big\} P(X=x)\\ &= \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]\\ &= \mathrm{ATE}\end{aligned}$$

となります．最後から 2 番目の等式では，繰り返し期待値の法則を使っています．つまり，共変量が同じ人どうしを比較して各層の処置効果を求め，その差を母集団の共変量分布で平均することにより，全体の ATE を識別できます．

6.2 回帰式に共変量を加えると ATE が推定できるか

本文では，共変量 X で層別して調整する方法を扱いました．では，回帰式に X を説明変数として加えるだけで平均処置効果が推定できるのでしょうか？結論から言えば，交互作用項を含む**飽和モデル**であれば各層の処置効果を復元できますが，交互作用を含まない回帰式の D の係数は，一般には ATE ではなく分散で重み付けされた平均になります．以下では本文の割引クーポンの例で計算し，そのあとで一般の場合を証明します．

本文のデータは次の 4 つのセルにまとめられます．$X=1$ がヘヴィユーザー，$X=0$ がライトユーザーです．

X	D	人数	Y
1（ヘヴィ）	1	3	3000
1（ヘヴィ）	0	1	2000
0（ライト）	1	1	200
0（ライト）	0	3	0

各層の処置効果は，ヘヴィが $3000-2000=1000$，ライトが $200-0=200$ です．どちらの層も 4 人ずついるので，ATE は $0.5\times 1000+0.5\times 200=600$ になります．

はじめに交互作用項を含む飽和モデル

$$Y=a+bD+cX+d\,(D\times X)+\varepsilon$$

を考えます．(D,X) の組み合わせは 4 通りで，パラメータも 4 つなので，このモデルは 4 つのセルの平均を誤差なく再現します．順に代入すると，$X=0,D=0$ より $a=0$，$X=0,D=1$ より $a+b=200$ すなわち $b=200$，$X=1,D=0$ より $a+c=2000$ すなわち $c=2000$，$X=1,D=1$ より $a+b+c+d=3000$ すなわち $d=800$ を得ます．したがって層ごとの処置効果は

$$\text{ライト：}\ b=200,\qquad \text{ヘヴィ：}\ b+d=200+800=1000$$

と復元でき，これを X の分布で平均すれば $0.5\times 200+0.5\times 1000=600$ となって ATE に一致します．ここで注意したいのは，D の係数 b そのものは ATE ではないという点です．b は $X=0$ の層における処置効果を表しており，ATE を得るには層ごとの効果を X の分布で平均し直す必要があります．

次に交互作用を含まない回帰式

$$Y=\alpha+\beta D+\gamma X+\varepsilon$$

の β を計算します．$\bar{D}=\bar{X}=0.5$, $\bar{Y}=1400$ です．D を X に回帰すると, $\mathrm{Cov}(D,X)=3/8-1/4=1/8$, $V(X)=1/4$ より傾きは 0.5, 切片は 0.25 なので, D の予測値は $X=1$ の層で 0.75，$X=0$ の層で 0.25 となります．これは各層の処置割当確率（傾向スコア）

に一致します．残差 $\tilde{D} = D - \hat{D}$ を使うと，

$$\begin{aligned}
\sum \tilde{D}Y &= 3(0.25)(3000) + 1(-0.75)(2000) \\
&\quad + 1(0.75)(200) + 3(-0.25)(0) \\
&= 2250 - 1500 + 150 = 900, \\
\sum \tilde{D}^2 &= 3(0.25)^2 + 1(0.75)^2 + 1(0.75)^2 + 3(0.25)^2 \\
&= 1.5
\end{aligned}$$

となり，$\beta = 900/1.5 = 600$ を得ます．この例では，交互作用を含まない回帰式でも ATE と一致しました．

しかし，これは偶然の一致です．一般に何が起きているかを確かめます．共変量による条件付き独立と一致性のもとで，$\mu_0(X) = \mathbb{E}[Y(0) \mid X]$，$\tau(X) = \mathbb{E}[Y(1) - Y(0) \mid X]$，$e(X) = P(D = 1 \mid X)$ とおくと

$$\mathbb{E}[Y \mid D, X] = \mu_0(X) + \tau(X)D$$

が成り立ちます．X が離散でダミー変数として飽和的に回帰式へ入っている場合，D を定数と X へ線形射影した予測値は $e(X)$ に一致するので，残差は $\tilde{D} = D - e(X)$ です．Frisch–Waugh–Lovell の定理より $\beta = \mathrm{Cov}(Y, \tilde{D})/V(\tilde{D})$ なので，まず分子を計算すると

$$\begin{aligned}
\mathbb{E}\big[Y(D - e(X))\big] &= \mathbb{E}\Big[\mathbb{E}[YD \mid X] - e(X)\mathbb{E}[Y \mid X]\Big] \\
&= \mathbb{E}\Big[e(X)\big(\mu_0(X) + \tau(X)\big) \\
&\qquad - e(X)\big(\mu_0(X) + e(X)\tau(X)\big)\Big] \\
&= \mathbb{E}\big[e(X)\{1 - e(X)\}\tau(X)\big]
\end{aligned}$$

となります．分母は $\mathbb{E}[(D - e(X))^2] = \mathbb{E}[e(X)\{1 - e(X)\}]$ です．したがって

$$\beta = \frac{\mathbb{E}\big[e(X)\{1 - e(X)\}\,\tau(X)\big]}{\mathbb{E}\big[e(X)\{1 - e(X)\}\big]}$$

が得られます．すなわち β は，各層の処置効果 $\tau(X)$ を，その層における処置割当の分散 $e(X)\{1 - e(X)\}$ で重み付けした平均です．一方 ATE は，同じ $\tau(X)$ を層の大きさ $P(X = x)$ で重み付けした平均でした．二つの重みが比例するときに限り，両者は一致します．

先ほどの例で一致したのは，ヘヴィの傾向スコアが $3/4$，ライトが $1/4$ で，どちらも $e(1 - e) = 3/16$ と等しく，さらに層の大きさも等しかったためです．たとえばヘヴィの

傾向スコアだけを 1/2 に変えると，重みは 1/4 と 3/16 になり，

$$\beta = \frac{\frac{1}{4} \times 1000 + \frac{3}{16} \times 200}{\frac{1}{4} + \frac{3}{16}} = \frac{287.5}{0.4375} \fallingdotseq 657.1$$

となって，ATE の 600 からずれます．処置効果が層によって異なる（$\tau(X)$ が一定でない）場合には，交互作用を含まない回帰式の係数を ATE として読むことはできません．逆に処置効果が層によらず一定であれば $\tau(X) = \tau$ となり，重みの取り方によらず $\beta = \tau =$ ATE が成り立ちます．

6.3 逆確率重み付け推定量の不偏性と一致性

真の傾向スコアを $e(X) = P(D = 1 \mid X)$ とし，共変量による条件付き独立，一致性，条件付き正値性が成り立つと仮定します．まず，処置を受けた人に関する項の条件付き期待値を考えます．一致性と条件付き独立により，

$$\begin{aligned}
\mathbb{E}\left[\frac{DY}{e(X)}\middle| X\right] &= \mathbb{E}\left[\frac{DY(1)}{e(X)}\middle| X\right] \\
&= \frac{\mathbb{E}[D \mid X]\mathbb{E}[Y(1) \mid X]}{e(X)} \\
&= \mathbb{E}[Y(1) \mid X]
\end{aligned}$$

となります．最後の等号では，$\mathbb{E}[D \mid X] = P(D = 1 \mid X) = e(X)$ を使いました．同様に，処置を受けなかった人に関する項についても，

$$\begin{aligned}
\mathbb{E}\left[\frac{(1-D)Y}{1-e(X)}\middle| X\right] &= \mathbb{E}\left[\frac{(1-D)Y(0)}{1-e(X)}\middle| X\right] \\
&= \mathbb{E}[Y(0) \mid X]
\end{aligned}$$

が成立します．条件付き正値性は，これらの式の分母が 0 にならないことを保証します．

したがって，繰り返し期待値の法則を用いると，

$$\begin{aligned}
&\mathbb{E}\left[\frac{DY}{e(X)} - \frac{(1-D)Y}{1-e(X)}\right] \\
&= \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] \\
&= \text{ATE}
\end{aligned}$$

となります．各観測値が同じ母集団から得られていれば，標本平均

$$\frac{1}{n}\sum_{i=1}^{n}\left\{\frac{D_i Y_i}{e(X_i)} - \frac{(1-D_i)Y_i}{1-e(X_i)}\right\}$$

の期待値も ATE に一致します．これが，真の傾向スコアを用いた IPW 推定量が ATE の不偏推定量になる理由です．

一方，本文で用いた正規化型では，処置群の平均を

$$\widehat{\mu}_1 = \frac{\sum_{i=1}^{n} D_i Y_i / e(X_i)}{\sum_{i=1}^{n} D_i / e(X_i)}$$

と計算します．観測値が独立同分布で，必要な期待値が有限ならば，大数の法則により，分子を n で割った値は上で示した $\mathbb{E}[Y(1)]$ に近づきます．分母についても

$$\mathbb{E}\left[\frac{D}{e(X)}\right] = \mathbb{E}\left[\frac{\mathbb{E}[D \mid X]}{e(X)}\right] = 1$$

なので，n で割った値は 1 に近づきます．したがって $\widehat{\mu}_1$ は $\mathbb{E}[Y(1)]$ に近づきます．統制群の正規化した平均も同様に $\mathbb{E}[Y(0)]$ に近づくため，二つの差は ATE の一致推定量です．ただし，比の形をとるため，有限標本での不偏性は一般には成り立ちません．

実際の分析では，通常，傾向スコアをデータから推定します．推定された傾向スコアを使う IPW 推定量は，有限標本で厳密に不偏になるとは限りません．ただし，傾向スコアモデルが正しく特定されているなどの条件のもとでは，一致推定量になります．

6.4 逆確率重み付けの計算過程（割引クーポンの例）

本文の割引クーポンの例について，逆確率で重み付けした平均の計算過程を示します．ヘヴィユーザーの傾向スコアは 3/4，ライトユーザーの傾向スコアは 1/4 でした．したがって処置群では，ヘヴィユーザーに 4/3 倍，ライトユーザーに 4 倍の重みがかかります．

処置群にはヘヴィユーザーが 3 人（各 3000 円），ライトユーザーが 1 人（200 円）含まれます．課金総額と人数のそれぞれに重みをかけると，

課金総額：

補正無し	補正後
$3000 \times 3 + 200 \times 1$	$3000 \times 3 \times \frac{4}{3} + 200 \times 1 \times \frac{4}{1}$

人数：

補正無し	補正後
$3 + 1$	$3 \times \frac{4}{3} + 1 \times \frac{4}{1}$

となります．よって補正後の平均（課金総額を人数で割った値）は

$$\frac{3000 \times 3 \times \frac{4}{3} + 200 \times 1 \times \frac{4}{1}}{3 \times \frac{4}{3} + 1 \times \frac{4}{1}} = 1600$$

です．

統制群についても同様です．統制群では，処置を受けない確率の逆数が重みになるので，ヘヴィユーザーには 4 倍，ライトユーザーには 4/3 倍の重みがかかります．統制群にはヘヴィユーザーが 1 人（2000 円），ライトユーザーが 3 人（各 0 円）含まれるので，

課金総額 :	
補正無し	補正後
$2000 \times 1 + 0 \times 3$	$2000 \times 1 \times \dfrac{4}{1} + 0 \times 3 \times \dfrac{4}{3}$
人数 :	
補正無し	補正後
$1 + 3$	$1 \times \dfrac{4}{1} + 3 \times \dfrac{4}{3}$

となり，補正後の平均は

$$\frac{2000 \times 1 \times \frac{4}{1} + 0 \times 3 \times \frac{4}{3}}{1 \times \frac{4}{1} + 3 \times \frac{4}{3}} = 1000$$

です．二つの平均の差 $1600 - 1000 = 600$ が，正しい平均処置効果に一致します．

6.5 傾向スコアによるバランシング性

同じ傾向スコアをもつ人々の中で，処置群と統制群の共変量分布が等しくなる仕組みを，人数を一般化して確認します．傾向スコア p の層に，共変量の組み合わせが異なる属性 A と属性 B があり，それぞれ N_A 人，N_B 人いるとします．どちらの属性にも同じ確率 p で処置が割り当てられるため，平均的な処置群の人数は pN_A 人と pN_B 人です．したがって，処置群における属性 A の構成比は

$$\frac{pN_A}{pN_A + pN_B} = \frac{N_A}{N_A + N_B}$$

となり，処置前の構成比と一致します．

統制群へ入る確率は，どちらの属性でも $1-p$ です．したがって，統制群における属性 A の構成比も

$$\frac{(1-p)N_A}{(1-p)N_A+(1-p)N_B}=\frac{N_A}{N_A+N_B}$$

となります．属性 B についても同様です．つまり，N_A と N_B がどのような値であっても，同じ傾向スコア p をもつ属性には同じ倍率が掛かるため，処置群と統制群で元の共変量分布が保たれます．属性が三種類以上ある場合にも，同じ計算が成り立ちます．

これは母集団上の確率，または割当てを繰り返したときの平均についての性質です．有限標本では実現人数が偶然にばらつくため，処置群と統制群の共変量分布が完全には一致しないことがあります．また，実際の分析では傾向スコアをデータから推定するため，推定モデルが不適切であれば十分なバランスが得られないこともあります．

共変量がさらに増えた場合のイメージは次の通りです．

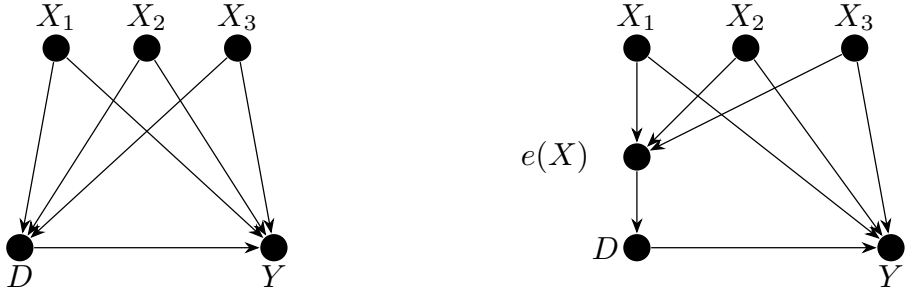


図 3　傾向スコア $e(X)=P(D=1\mid X)$ による調整のイメージ

以上の性質を，共変量が二つある具体例で確かめておきます．ユーザータイプと年齢を共変量とし，ヘヴィユーザーほど処置を受けやすく，30 歳以上の人は処置を受けにくいとします．次の表のような人数と傾向スコアが得られたとしましょう．

表 2　二つの共変量と傾向スコアの例

ユーザータイプ	年齢	人数	傾向スコア	処置群	統制群
ヘヴィ	30 歳未満	100	0.8	80	20
ヘヴィ	30 歳以上	120	0.6	72	48
ライト	30 歳未満	80	0.6	48	32
ライト	30 歳以上	100	0.4	40	60

傾向スコア 0.8 の層には「ヘヴィ・30 歳未満」だけ，0.4 の層には「ライト・30 歳以上」だけが含まれます．それぞれ共変量の組み合わせが一種類しかないため，処置群と統制群

の共変量分布が等しくなることは自明です．ここで注目したいのは，灰色で示した二つの組み合わせです．「ヘヴィ・30 歳以上」と「ライト・30 歳未満」は，共変量の組み合わせは異なりますが，どちらも傾向スコアは 0.6 です．この 0.6 の層だけを取り出すと，次の表のようになります．

表 3　傾向スコア 0.6 の層における共変量分布

共変量の組み合わせ	処置群	統制群
ヘヴィ・30 歳以上	72 人（60%）	48 人（60%）
ライト・30 歳未満	48 人（40%）	32 人（40%）
合計	120 人	80 人

処置群では二つの属性が 72 人と 48 人なので，構成比は 60% と 40% です．統制群でも 48 人と 32 人なので，構成比は同じく 60% と 40% です．つまり，同じ傾向スコアの層の中では，処置群と統制群で共変量の組み合わせの分布が等しくなります．これは各属性が半数ずつになるという意味ではなく，もとの 120 人（ヘヴィ・30 歳以上）対 80 人（ライト・30 歳未満），すなわち 60% 対 40% という構成比が両群で保たれるという意味です．冒頭の一般的な計算で $N_A = 120$，$N_B = 80$，$p = 0.6$ としたものにあたり，元の人数が別の値でも，同じ傾向スコアが各属性に掛かるため性質は変わりません．この例から分かるように，傾向スコアが 0.5 である必要もありません．

次に，共変量 X で条件づけたときに処置 D と潜在的結果が独立なら，傾向スコア $e(X)$ で条件づけたときにも独立になることを示します．潜在的結果の組を $Z = (Y(0), Y(1))$ とおき，

$$Z \perp D \mid X$$

を仮定します．処置が二値変数であることを用いると，

$$\begin{aligned} P(D = 1 \mid Z, e(X)) &= \mathbb{E}[P(D = 1 \mid Z, X, e(X)) \mid Z, e(X)] \\ &= \mathbb{E}[P(D = 1 \mid X) \mid Z, e(X)] \\ &= \mathbb{E}[e(X) \mid Z, e(X)] \\ &= e(X) \\ &= P(D = 1 \mid e(X)) \end{aligned}$$

となります．2 番目の等号では $Z \perp D \mid X$ を使い，最後の等号では傾向スコアの定義を使いました．したがって，傾向スコアが同じ人々の中では，潜在的結果の値を知っても処

置確率は変わらず，

$$(Y(0), Y(1)) \perp D \mid e(X)$$

が成立します．詳しくは Imbens and Rubin (2015: 266–268)，宮川（2004: 31）を参照してください．

6.6 傾向スコアマッチングで ATE を推定する条件

傾向スコアが近い処置群と統制群の個体を対応させれば，つねに ATE を推定できるわけではありません．マッチングで ATE を一致推定するには，まず，共変量による条件付き独立，一致性，条件付き正値性が必要です．これらの条件のもとでは，前節で示したように

$$(Y(0), Y(1)) \perp D \mid e(X)$$

が成り立ちます．したがって，傾向スコアが p である層の平均処置効果は，

$$\tau(p) = \mathbb{E}[Y \mid D = 1, e(X) = p] - \mathbb{E}[Y \mid D = 0, e(X) = p]$$

によって識別できます．

集団全体の ATE を求めるには，この層別の処置効果を，対象集団における傾向スコアの分布で平均する必要があります．すなわち，

$$\text{ATE} = \mathbb{E}[\tau(e(X))]$$

です．傾向スコアが離散的な場合には，

$$\text{ATE} = \sum_{p} \tau(p) P(e(X) = p)$$

と書けます．したがって，各層の処置効果を同じ重みで単純平均するだけでは，層の人数が異なる場合に ATE と一致しません．本文の例では，ヘヴィとライトがそれぞれ 4 人であるため，二つの層の重みはいずれも $1/2$ となり，

$$\frac{1}{2} \times 1000 + \frac{1}{2} \times 200 = 600$$

が ATE に一致します．

実際のデータでは，傾向スコアが完全に等しい個体が見つかるとは限らないため，通常は最も近い傾向スコアをもつ個体どうしを対応させます．このとき一致推定を保証するには，いくつかの条件が加わります．まず傾向スコアが正しく与えられるか，標本の増加と

ともに真の傾向スコアへ近づくように推定されている必要があります．またマッチした個体間の傾向スコアの差が，標本の増加とともに 0 へ近づかなければなりません．さらに，傾向スコアで条件づけた結果変数の平均が滑らかに変化し，極端な外れ値によって平均が不安定にならないことも求められます．ATE を推定する場合には，処置群と統制群の両方について反実仮想の結果を補い，対象集団全体の構成を反映して平均する必要があります．

一方，処置を受けた個体だけを基準にして，それぞれに統制群の個体を対応させた場合，推定対象は通常，処置群に対する平均処置効果

$$\mathrm{ATT} = \mathbb{E}[Y(1) - Y(0) \mid D = 1]$$

です．ATE と ATT のどちらを推定するかは，マッチングという名称だけでは決まらず，誰を基準にマッチさせ，マッチ後の差をどのような重みで集計するかによって決まります．

6.7 二重にロバストな推定

二重にロバストな推定では，二つのモデルを組み合わせます．一つは**アウトカム回帰**（Outcome Regression, RA）で，処置群と統制群のそれぞれについて $m_d(X) = \mathbb{E}[Y \mid D = d, X]$ をモデル化し，各個体の $Y(1)$ と $Y(0)$ に対応する予測値を作って，その差を平均することで ATE を推定します．線形モデルに限らず，非線形モデルも利用できます．もう一つは**逆確率重み付け**（IPW）で，傾向スコア $e(X) = P(D = 1 \mid X)$ をモデル化し，処置を受けにくいのに実際に受けた個体や，処置を受けやすいのに実際には受けなかった個体へ大きな重みを与えて ATE を推定します．

拡大逆確率重み付け推定量（Augmented Inverse Probability Weighting: AIPW）は，アウトカム回帰による予測を IPW によって補正します．共変量による条件付き独立，一致性，条件付き正値性などの識別条件が満たされているもとで，アウトカム回帰モデル $m_d(X)$ と傾向スコアモデル $e(X)$ のどちらか一方が正しく特定されていれば，ATE の一致推定量になります．この性質を**二重にロバストな推定**（Doubly Robust Estimation）と呼びます（Robins et al. 1994）．

ここでロバストなのは二つの統計モデルの特定に対してであり，識別条件の違反に対してではありません．未観測交絡がある場合や条件付き正値性が成り立たない場合には，二重にロバストな推定量を使うだけでは問題を解決できません．また，二つのモデルがともに誤っている場合，一致性は保証されません．

8　第 8 章に対応する補足資料

8.1　調整化公式の導出

Z が X と Y の交絡変数であり，因果ダイアグラムが $Z \to X$，$Z \to Y$，$X \to Y$ という構造をもつ場合を考えます．$X = x$ への介入によって生じる仮想的世界の確率を P_m と書くと，介入分布は

$$P(Y = y \mid do(X = x)) = P_m(Y = y \mid X = x)$$

と表せます．

介入では X の値を外から x に固定するため，Z から X への矢線は取り除かれます．一方，介入は Z の分布や，X と Z から Y が生じる仕組みを変えません．したがって，

$$P_m(z \mid x) = P_m(z) = P(z),$$
$$P_m(y \mid x, z) = P(y \mid x, z)$$

が成立します．一つ目の式は，介入後には X が固定されて Z の影響を受けなくなり，かつ Z 自体の分布は介入前後で変わらないことを表しています．二つ目の式は，介入によって Y が生じる仕組みは変更されないことを表しています．

これらを使って介入分布を Z について周辺化すると，

$$\begin{aligned} P(y \mid do(x)) &= P_m(y \mid x) \\ &= \sum_z P_m(y \mid x, z) P_m(z \mid x) \\ &= \sum_z P(y \mid x, z) P(z) \end{aligned}$$

となります．これが本文で用いた調整化公式です．介入後の分布を，介入前の観察データから得られる $P(y \mid x, z)$ と $P(z)$ だけで計算できることを示しています．

8.2　調整化公式と共変量による調整との一致

「共変量の調整が機能する理由」では，潜在的結果モデルにおいて，共変量による条件付き独立，一致性，条件付き正値性が成り立つときに ATE を識別できることを示しました．そこで用いた処置変数 D を X，共変量 X を Z と書き換えると，Z が離散変数の場合，

$$\mathrm{ATE} = \sum_z \Big\{ \mathbb{E}[Y \mid X = 1, Z = z] - \mathbb{E}[Y \mid X = 0, Z = z] \Big\} P(Z = z)$$

となります.

一方，構造的因果モデルにおいて Z がバックドア基準を満たすとき，調整化公式

$$\mathbb{E}[Y \mid do(X = x)] = \sum_z \mathbb{E}[Y \mid X = x, Z = z]P(Z = z)$$

が成り立ちます．したがって，$x = 1$ の場合と $x = 0$ の場合の差を取ると，

$$\begin{aligned}
&\mathbb{E}[Y \mid do(X = 1)] - \mathbb{E}[Y \mid do(X = 0)] \\
&= \sum_z \Big\{ \mathbb{E}[Y \mid X = 1, Z = z] - \mathbb{E}[Y \mid X = 0, Z = z] \Big\} P(Z = z) \\
&= \text{ATE}
\end{aligned}$$

となります．つまり，バックドア基準を満たす共変量で調整した潜在的結果モデルの平均処置効果と，構造的因果モデルにおける介入の平均因果効果は，同じ観測分布から同じ式によって計算されます.

8.3 チェーン構造における理論上の平均因果効果

本文のチェーン構造（$X \to Z \to Y$）の例で，X の Y への理論的な因果効果を確かめます．構造方程式は

$$\begin{aligned}
X &= U_1, \\
Z &= 2X + U_2, \\
Y &= -2Z + U_3
\end{aligned}$$

です.

介入 $do(X = x)$ を行うと，第 1 式は

$$X := x$$

に置き換えられます．このとき第 2 式は

$$Z = 2x + U_2$$

となります．これを第 3 式に代入すると，

$$\begin{aligned}
Y &= -2(2x + U_2) + U_3 \\
&= -4x - 2U_2 + U_3
\end{aligned}$$

です．よって介入分布の期待値は

$$\begin{aligned}\mathbb{E}[Y \mid do(X = x)] &= \mathbb{E}[-4x - 2U_2 + U_3] \\ &= -4x - 2\mathbb{E}[U_2] + \mathbb{E}[U_3]\end{aligned}$$

となります．外生変数 U_2, U_3 の平均は 0 と仮定しているので，

$$\mathbb{E}[Y \mid do(X = x)] = -4x$$

です．したがって，

$$\frac{d}{dx}\mathbb{E}[Y \mid do(X = x)] = -4$$

となります．ゆえに，この線形構造方程式モデルにおける X の Y への平均因果効果は -4 です．

9　第 9 章に対応する補足資料

9.1　操作変数推定量と確率収束

本文では，操作変数 Z を使うと，未観測交絡変数 W を直接観測しなくても

$$\beta = \frac{\mathrm{Cov}(Z, Y)}{\mathrm{Cov}(Z, X)}$$

として因果効果を識別できることを確認しました．ここでは，この母集団上の共分散の比を，標本データからどのように推定するかを補足します．

母共分散は観測できないので，実際のデータ分析では標本共分散で置き換えます．すなわち，

$$\hat{\beta} = \frac{\sum_{i=1}^{n}(Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(Z_i - \bar{Z})(X_i - \bar{X})}$$

という推定量を使います．これは，Z と Y の標本共分散を，Z と X の標本共分散で割ったものです．

この推定量が真の値に近づく理由を確認します．いま，結果方程式を

$$Y_i = \alpha + \beta X_i + U_i$$

と書き，操作変数の条件として

$$\mathrm{Cov}(Z, U) = 0, \qquad \mathrm{Cov}(Z, X) \neq 0$$

が成り立つとします．このとき，

$$\begin{aligned}\hat{\beta} &= \frac{\sum_{i=1}^{n}(Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(Z_i - \bar{Z})(X_i - \bar{X})} \\ &= \frac{\sum_{i=1}^{n}(Z_i - \bar{Z})(\alpha + \beta X_i + U_i)}{\sum_{i=1}^{n}(Z_i - \bar{Z})(X_i - \bar{X})} \\ &= \beta + \frac{\sum_{i=1}^{n}(Z_i - \bar{Z})(U_i - \bar{U})}{\sum_{i=1}^{n}(Z_i - \bar{Z})(X_i - \bar{X})}\end{aligned}$$

となります．両辺の分子分母を n で割ると，

$$\hat{\beta} = \beta + \frac{\frac{1}{n}\sum_{i=1}^{n}(Z_i - \bar{Z})(U_i - \bar{U})}{\frac{1}{n}\sum_{i=1}^{n}(Z_i - \bar{Z})(X_i - \bar{X})}$$

です．標本サイズが大きくなると，分子は $\mathrm{Cov}(Z, U)$ に，分母は $\mathrm{Cov}(Z, X)$ に近づきます．したがって，

$$\begin{aligned}\operatorname{plim}\hat{\beta} &= \beta + \frac{\mathrm{Cov}(Z, U)}{\mathrm{Cov}(Z, X)} \\ &= \beta + \frac{0}{\mathrm{Cov}(Z, X)} \\ &= \beta\end{aligned}$$

となります．ここで plim は，標本サイズを大きくしていったときに推定量が近づいていく値（確率極限）を表します．つまり，操作変数の条件が成り立ち，標本サイズが十分大きくなると，この推定量は真の値 β に確率収束します．直感的には，標本サイズが大きくなるにつれて，標本共分散が母共分散に近づくため，共分散の比で作った推定量も母集団上の比に近づく，ということです．

9.2 操作変数の条件：DAG の言葉と回帰式の言葉

本文では，操作変数の条件を二通りの方法で説明しました．一つは，次のように DAG の言葉で書いた条件です．

- 処置変数 X に影響する（関連性）
- 未観測交絡変数 W と独立である（独立性）
- 結果変数 Y には X を通してのみ影響する（除外制約）

もう一つは，コラム「操作変数で未観測交絡を取り除ける理由」で使った，回帰式の誤差

項と共分散による書き方です．こちらは計量経済学でよく使われます．二つの書き方は同じ考えを表していますが，その対応は少し分かりにくいので，ここで整理します．

DAG で表した条件

本文の教育バウチャーの例を図 4 に示します．Z はバウチャーの当選，X は私立高校への進学，Y はテスト得点，W は未観測の要因（家庭環境など）です．

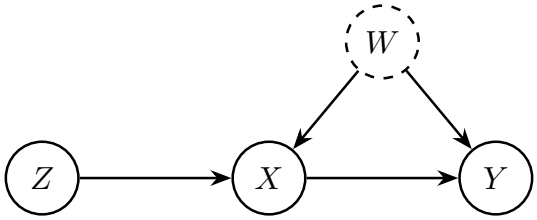


図 4　操作変数 Z の因果ダイアグラム．点線の W は未観測

三つの条件は，DAG の上では次のように読めます．

- 関連性：Z から X への矢線がある．
- 独立性：Z と W が独立である．W から Z への矢線も，Z と W の共通の原因もない．
- 除外制約：Z から Y への矢線がなく，Z から Y への有向パスはすべて X を通る．

独立性と除外制約は，データから直接確かめることができない仮定です．バウチャーの例でいえば，抽選が公正でなく裕福な家庭ほど当選しやすかったなら，独立性の仮定に反します．当選したことで生徒のやる気が高まり，進学先とは関係なくテスト得点が上がったなら，除外制約の仮定に反します．

回帰式で表した条件

計量経済学では，次の回帰式から出発します．

$$Y = \alpha + \beta X + u$$

u は誤差項で，X 以外に Y を動かす要因がすべてここに入ります．操作変数の条件は

- $\mathrm{Cov}(Z, X) \neq 0$（関連性）
- $\mathrm{Cov}(Z, u) = 0$（Z と誤差項が相関しない）

の二つです．DAG の三条件と比べると，条件が一つ少なくなっています．DAG の独立

性と除外制約が，$\mathrm{Cov}(Z,u)=0$ という一つの条件にまとめられていると考えると分かりやすいでしょう．次に，この対応を確かめます．

二つの書き方の対応

図 4 に合う線形の構造的因果モデルを考えます．

$$X=\pi Z+\delta W+U_X$$
$$Y=\beta X+\gamma W+U_Y$$

Z,W,U_X,U_Y は互いに独立で，平均はいずれも 0 とします．Y の式を回帰式 $Y=\alpha+\beta X+u$ と見比べると，$\alpha=0$ で，誤差項は

$$u=\gamma W+U_Y$$

です．つまり誤差項 u には，未観測交絡 W の影響と外生変数 U_Y の両方が入っています．Z は W とも U_Y とも独立なので $\mathrm{Cov}(Z,u)=0$ が成り立ち，本文のコラムと同じ計算によって

$$\beta=\frac{\mathrm{Cov}(Z,Y)}{\mathrm{Cov}(Z,X)}$$

が得られます．

では，DAG の条件に反する場合はどうなるでしょうか？　二つの場合を考えます．

第一に，除外制約の仮定に反して，Z が Y に直接影響する場合です．Y の式は $Y=\beta X+\gamma W+\lambda Z+U_Y$ となるので，誤差項は $u=\gamma W+\lambda Z+U_Y$ です．すると

$$\mathrm{Cov}(Z,u)=\lambda V(Z)\neq 0$$

となります．

第二に，独立性の仮定に反して，Z が W と相関する場合です．このとき

$$\mathrm{Cov}(Z,u)=\gamma\mathrm{Cov}(Z,W)\neq 0$$

となります．

どちらの場合も $\mathrm{Cov}(Z,u)\neq 0$ となり，共分散の比は β からずれてしまいます．このように，回帰式の条件 $\mathrm{Cov}(Z,u)=0$ は，DAG の独立性と除外制約をまとめて表したものと理解できます．DAG で書く利点は，どちらの仮定が疑わしいのかを分けて議論でき

る点にあります．回帰式で書くと，どちらが原因であっても「Z と誤差項が相関する」という一つの問題として現れます[*3]．

ここで，誤差項 u と構造的因果モデルの外生変数 U_Y は別のものだという点に注意してください．第一の場合でも，Z と U_Y は独立なので $\mathrm{Cov}(Z, U_Y) = 0$ のままです．Z が操作変数として使えなくなるのは，U_Y ではなく u のほうに λZ が入り込むからです．本文のコラムの脚注で「誤差項に関する設定が異なる」と述べたのは，この違いのことです．

何の効果が推定できるのか

本文では，処置効果がすべての個体で同じ値 β だと仮定しました．この仮定のもとでは，共分散の比は平均処置効果に一致します．

では，効果が人によって異なる場合はどうなるでしょうか？　バウチャーの例で，抽選の結果によって進学先がどう変わるかに注目して，家庭を四つのタイプに分けてみます．

表 4　抽選の結果と進学先による四つのタイプ

タイプ	当選した場合	落選した場合
いつも私立	私立	私立
いつも公立	公立	公立
コンプライヤー	私立	公立
反抗者	公立	私立

「いつも私立」と「いつも公立」の家庭は，抽選の結果に関係なく進学先が決まっています．当選者と落選者を比べても，この人たちの処置は変わらないので，私立進学の効果については何も分かりません．抽選の結果に応じて進学先を変えるのは，コンプライヤーと反抗者だけです．

そこで，当選したのにあえて公立を選び，落選したら私立を選ぶ反抗者はいない，と仮定します．この仮定を単調性といいます．Z と X がどちらも 0 か 1 をとる場合，本文の三条件と単調性のもとで，共分散の比はコンプライヤーにおける平均処置効果に一致します（Imbens and Angrist 1994）．これを局所平均処置効果（Local Average Treatment Effect: LATE）と呼びます．本文第 9 章の脚注で「操作変数に反応して処置の値が変わ

[*3] 厳密には，二つの書き方は完全に同じではありません．たとえば $\lambda V(Z) + \gamma \mathrm{Cov}(Z, W) = 0$ のように，除外制約に反する影響と独立性に反する影響がちょうど打ち消し合えば，DAG の条件に反していても $\mathrm{Cov}(Z, u) = 0$ となります．

る人たち」と書いたのは，このコンプライヤーのことです．

LATE は，集団全体の平均処置効果（ATE）と一般には一致しません．バウチャーに当選したから私立に進む家庭と，もともと私立に進むつもりの家庭とでは，私立進学の効果が違うかもしれないからです．操作変数による推定値を読むときは，それが誰にとっての効果なのかに注意が必要です．

さらに単調性も仮定しない場合には，平均処置効果を一つの値に定めることはできません．ただし，Z, X, Y がすべて二値であれば，平均処置効果がとりうる範囲（上限と下限）をデータから計算できます（Balke and Pearl 1997）．

以上をまとめると，操作変数を使って分かることは，置く仮定によって次のように変わります．

表 5　追加の仮定と操作変数から分かること

追加の仮定	分かること
処置効果が全員で同じ	平均処置効果（ATE）
単調性	コンプライヤーの平均処置効果（LATE）
なし	平均処置効果のとりうる範囲

9.3　フロントドア基準による調整

本文の健康食品の例をもとに，フロントドア基準による調整公式を確認します．変数は次のように対応しています．

X：健康食品の摂取,　　M：血行,　　Y：健康度,　　W：健康志向（未観測）

想定する因果ダイアグラムは次の形です．

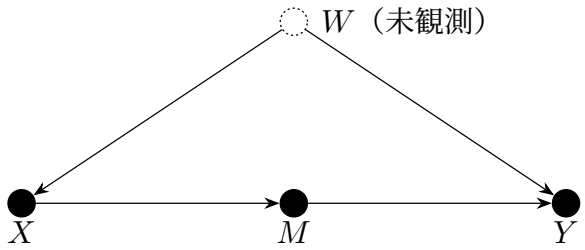


図 5　フロントドア基準の基本形

このDAGでは，W が未観測なので，X から Y へのバックドアパス

$$X \leftarrow W \rightarrow Y$$

を W で調整することはできません．しかし，媒介変数 M が次の三つの条件を満たすため，フロントドア基準によって X から Y への因果効果を識別できます．

1. X から Y へのすべての有向パスは M を通る．
2. X から M へのバックドアパスはない．
3. M から Y へのバックドアパスは X でブロックできる．

示したい式は，

$$P(Y = y \mid do(X = x)) = \sum_m P(M = m \mid X = x) \sum_{x'} P(Y = y \mid M = m, X = x')P(X = x')$$

です．右辺はすべて観測可能な分布で書かれています．

第一段階：X から M への効果

まず $P(m \mid do(x))$ を考えます．条件2より，X から M へのバックドアパスはありません．したがって，X を x に介入したときの M の分布は，観測データで $X = x$ だった人たちの M の分布と一致します．

$$P(m \mid do(x)) = P(m \mid x) \tag{1}$$

健康食品の例で言えば，「健康食品を強制的に x だけ摂らせたときの血行の分布」は，「観測データ上で健康食品摂取量が x だった人の血行の分布」から読める，ということです．

第二段階：M から Y への効果

次に $P(y \mid do(m))$ を考えます．条件3より，M から Y へのバックドアパスは X でブロックできます．したがって，X で調整することで，

$$P(y \mid do(m)) = \sum_{x'} P(y \mid m, x')P(x') \tag{2}$$

と書けます．ここで重要なのは，右辺に未観測変数 W が含まれていないことです．

健康食品の例で言えば，「血行 M が健康度 Y に与える効果」は，健康食品摂取量 X で調整しながら，血行と健康度の関係を見ることで計算できます．

第三段階：二つの効果を組み合わせる

最後に，二つの効果を組み合わせます．X を x に介入すると，M は分布 $P(m \mid do(x))$ に従って値をとり，$M = m$ となった人の Y は分布 $P(y \mid do(x), m)$ に従います．したがって，介入分布は M の値ごとに分けて

$$P(y \mid do(x)) = \sum_m P(y \mid do(x), m) P(m \mid do(x))$$

と書けます．

ここで，$P(y \mid do(x), m)$ は $P(y \mid do(m))$ に置き換えられます．理由は二つあります．

一つ目に，X に介入すると W から X への矢線が取り除かれるので，M から Y へのバックドアパス $M \leftarrow X \leftarrow W \rightarrow Y$ はなくなります．バックドアパスがなければ，「$M = m$ であることを観測する」ことと「M を m に介入して固定する」ことは同じ結果を与えます．

二つ目に，条件 1 より X は M を通してしか Y に影響しません．そのため，M の値を m に固定してしまえば，X をどの値に介入しても Y の分布は変わりません．

この二つをまとめると，

$$P(y \mid do(x), m) = P(y \mid do(x), do(m)) = P(y \mid do(m)) \tag{3}$$

となります．最初の等号が一つ目の理由，次の等号が二つ目の理由に対応します[*4]．

(1)，(2)，(3) を代入すると，

$$\begin{aligned} P(y \mid do(x)) &= \sum_m P(y \mid do(x), m) P(m \mid do(x)) \\ &= \sum_m P(y \mid do(m)) P(m \mid x) \\ &= \sum_m P(m \mid x) \sum_{x'} P(y \mid m, x') P(x') \end{aligned}$$

となります．よって，

$$P(Y = y \mid do(X = x)) = \sum_m P(M = m \mid X = x) \sum_{x'} P(Y = y \mid M = m, X = x') P(X = x')$$

が得られます．

この導出では関数形を線形に限定していません．したがって，フロントドア基準は線形モデルに限らず，DAG 上の条件が正しく満たされる場合に適用できる識別基準です．

[*4] この二つの置き換えは，do 演算の規則（第 2 規則と第 3 規則）を使って厳密に示せます．詳しくは Pearl (2009) を参照してください．

10　第 10 章に対応する補足資料

10.1　反実仮想の練習問題の解答

本文第 10 章「猫ちゃんで学ぶ反実仮想」の練習問題の解答を示します．構造方程式は

$$Y = UX + (1-U)(1-X)$$

で，$X = 1$ は猫を飼う，$X = 0$ は猫を飼わない，$Y = 1$ は幸福，$Y = 0$ は幸福でない，$U = 1$ は猫派，$U = 0$ は犬派を表します．どちらの問題も本文と同じ三つの手順（推測・介入・予測）で解きます．

問題 1：データ $X = 1$，$Y = 0$ の人が，猫を飼わなかったら？

手順 1（推測）：構造方程式にデータ $X = 1$，$Y = 0$ を代入すると

$$0 = U \cdot 1 + (1-U)(1-1) = U \Rightarrow U = 0$$

です．この個体は犬派だと分かります．猫を飼っているのに幸福でない，という事実がそれを教えてくれます．

手順 2（介入）：反事実的な処置 $X = 0$ のもとでモデルを修正します．Y の構造方程式の X を 0 に置き換えると，修正後のモデルの構造方程式は

$$Y = U \cdot 0 + (1-U)(1-0) = 1 - U$$

となります．

手順 3（予測）：修正後のモデルに，手順 1 で特定した外生変数の値 $U = 0$ を代入します．

$$Y_0(U = 0) = 1 - 0 = 1$$

猫を飼っていて幸福でない人は犬派なので，もし猫を飼わなかったとしたら幸福だった，という反実仮想を得ます．

問題 2：データ $X = 1$，$Y = 1$ の人が，猫を飼わなかったら？

手順 1（推測）：構造方程式にデータ $X = 1$，$Y = 1$ を代入すると

$$1 = U \cdot 1 + (1-U)(1-1) = U \Rightarrow U = 1$$

です．この個体は猫派だと分かります．

手順 2（介入）：問題 1 と同じく $X = 0$ のもとでモデルを修正するので，修正後のモデルの構造方程式は

$$Y = U \cdot 0 + (1 - U)(1 - 0) = 1 - U$$

となります．

手順 3（予測）：修正後のモデルに $U = 1$ を代入します．

$$Y_0(U = 1) = 1 - 1 = 0$$

猫を飼っていて幸福な人は猫派なので，もし猫を飼わなかったとしたら幸福ではなかった，という反実仮想を得ます．

本文の二つの例と合わせると，観測されうる四つのパターンすべてについて反実仮想が求まったことになります．

表 6　四つの観測パターンに対する反実仮想

観測された (X, Y)	推測される U	反実仮想
$(0, 0)$ 飼わず不幸	1（猫派）	$Y_1(U = 1) = 1$
$(0, 1)$ 飼わず幸福	0（犬派）	$Y_1(U = 0) = 0$
$(1, 0)$ 飼って不幸	0（犬派）	$Y_0(U = 0) = 1$
$(1, 1)$ 飼って幸福	1（猫派）	$Y_0(U = 1) = 0$

四つとも，処置を反転させると結果も反転しています．これはこのモデルが，幸福を「嗜好 U と選択 X が一致するかどうか」で決めているためです．実際，構造方程式 $Y = UX + (1 - U)(1 - X)$ は $U = X$ のとき $Y = 1$，$U \neq X$ のとき $Y = 0$ と書き直せます．嗜好 U を固定したまま選択 X だけを変えれば，一致・不一致が必ず入れ替わります．

この反転がつねに起こるのは，モデルが単純だからです．外生変数が三つ以上の値をとる場合には，処置を変えても結果が変わらない個体が現れます．本文の確率的な反実仮想の例では，超楽観主義（$U = 1$）の人は猫を飼っても飼わなくても幸福で，超悲観主義（$U = 2$）の人はどちらでも幸福ではありません．

10.2　反実仮想の計算とベイズ統計

本文第 10 章では，猫の例に即して反実仮想の計算がベイズ統計とどう対応するかを述べました．ここでは一般の構造的因果モデルについて同じ対応を整理します．

構造的因果モデルが

$$X = f_X(U_X), \qquad Y = f_Y(X, U_Y)$$

で与えられ，U_X, U_Y は外生変数だとします．ある個体について $X = x$，$Y = y$ が観測されたとき，「もしこの個体について $X = x'$ だったならば Y はどうなっていたか」を問うのが反実仮想で，その値を $Y_{x'}$ と書きます．本文と同じく，プライムのない記号が実際に観測された値，プライムを付けた記号が仮想の値を表します．計算はアブダクション（abduction），行動（action），予測（prediction）の三段階からなります（Pearl 2000=2009）．

第一段階のアブダクションでは，観測された事実 $e = (X = x,\ Y = y)$ を使って外生変数の分布を更新します．ベイズの定理により

$$P(U \mid e) = \frac{P(e \mid U) P(U)}{P(e)} \propto P(e \mid U)\, P(U)$$

です．これはベイズ統計における事前分布から事後分布への更新 $p(\theta) \to p(\theta \mid D)$ とほぼ同じ操作ですが，更新する対象が違います．通常のベイズ統計では母集団の未知パラメータ θ の分布を更新するのに対し，ここで更新するのは観測されたこの個体の外生変数 U の分布です．

第二段階の行動では，$do(X = x')$ という介入を行います．構造方程式 $X = f_X(U_X)$ を削除して $X := x'$ という方程式に置き換えるので，介入後のモデルでは $X = x'$，$Y = f_Y(x', U_Y)$ となります．元のモデルを M とすれば，この操作はモデルそのものの書き換え $M \to M_{x'}$ にあたり，model surgery と呼ばれます．この段階に対応するものは通常のベイズ統計にはありません．

第三段階の予測では，アブダクションで得た $P(U \mid e)$ を書き換え後のモデル $M_{x'}$ に適用します．離散変数であれば

$$P(Y_{x'} = y' \mid e) = \sum_{u_Y} I\{f_Y(x', u_Y) = y'\}\, P(u_Y \mid e)$$

と書けます．これはベイズ統計の事後予測分布

$$p(y_{\text{new}} \mid D) = \int p(y_{\text{new}} \mid \theta)\, p(\theta \mid D)\, d\theta$$

と同じ形をしています．対応関係を並べると表 7 のようになります．

処置の割当が外生変数に依存する場合

本文の猫の例を使って，処置 X の割当が外生変数 U に依存する場合を考えます．外生変数の事前分布と結果 Y の構造方程式は本文と同じとし，猫派（$U = 3$）は猫を飼いやすく，それ以外のタイプは猫を飼いにくいと仮定します．具体的には，

$$P(X = 1 \mid U = 3) = \frac{3}{4}, \qquad P(X = 1 \mid U \neq 3) = \frac{1}{4}$$

とします．

猫を飼っておらず幸福でない人（$X = 0, Y = 0$）について，もし猫を飼ったら幸福になるかを考えます．観測事実と両立するタイプは，本文と同じく超悲観主義（$U = 2$）と猫派（$U = 3$）です．ただし今回は，それぞれの事前確率だけでなく，そのタイプの人が $X = 0$ になる確率も使います．正規化前の重みは

$$P(U = 2)P(X = 0 \mid U = 2) = 0.2 \times \frac{3}{4} = 0.15,$$
$$P(U = 3)P(X = 0 \mid U = 3) = 0.4 \times \frac{1}{4} = 0.10$$

です．したがって，外生変数の事後分布は

$$P(U = 2 \mid X = 0, Y = 0) = \frac{0.15}{0.15 + 0.10} = \frac{3}{5},$$
$$P(U = 3 \mid X = 0, Y = 0) = \frac{0.10}{0.15 + 0.10} = \frac{2}{5}$$

となります．

次に $do(X = 1)$ によってモデルを書き換えます．上の二つのタイプのうち，猫を飼うことで幸福になるのは猫派（$U = 3$）だけです．したがって，

$$P(Y_1 = 1 \mid X = 0, Y = 0) = P(U = 3 \mid X = 0, Y = 0) = \frac{2}{5}$$

となります．本文では X と U が独立なので答えは $2/3$ でしたが，ここでは「猫を飼っていない」という事実が，その人が猫派である可能性を下げる情報にもなるため，反実仮想確率は $2/5$ に変わります．一般に処置の割当が U に依存する場合，手順 1 では事前確率 $P(U = u)$ だけでなく，割当の尤度 $P(X = x \mid U = u)$ も掛けて事後分布を計算します．

表 7　ベイズ統計と反実仮想の対応（一般形）

ベイズ統計	構造的因果モデルにおける反実仮想
$p(\theta)$	$P(U)$
$p(\theta \mid D)$	$P(U \mid e)$
$p(y_{\text{new}} \mid \theta)$	$P(Y_{x'} \mid U)$
$p(y_{\text{new}} \mid D)$	$P(Y_{x'} \mid e)$

まとめると，反実仮想の計算はベイズの条件づけ（アブダクション）と構造的介入（行動）と事後予測に似た計算（予測）の三つからなり，中央の構造的介入だけがベイズ統計に対応物を持ちません．通常のベイズ事後予測が「データ D を得たあと新しい観測 y_{new} はどうなるか」を問うのに対し，反実仮想は「実際に観測されたこの個体について，外生変数 U は同じまま X を x' に変更したならどうなるか」を問います．

反実仮想分布 $P(Y_{x'} = y' \mid e)$ と，新たな個体について $X = x'$ を観測したときの予測分布は，一般に同じではありません．処置割当の外生変数 U_X と結果の外生変数 U_Y が独立であっても，観測された結果 $Y = y$ が U_Y についての情報を与えるからです．本文第 10 章で，集団への介入と，観測された特定の個体についての反実仮想が異なる答えを与えたのもそのためです．両者が一致するのは，証拠 e が介入後の結果を左右する外生変数について追加の情報を与えない場合などに限られます．

10.3　潜在的結果モデルと構造的因果モデルの反実仮想の違い

本文では潜在的結果モデルと構造的因果モデルという二つの枠組みを扱いました．両者における反実仮想はいったい何が違うのか，表現の方法が異なるだけで同じなのか，という疑問を持たれたかもしれません．

両者には多くの数学的な共通点がありますが，概念的に因果のとらえ方が少し異なるので以下にその特徴を確認します．

潜在的結果モデル

潜在的結果モデルでは，各個体 i について

$$Y_i(1), \quad Y_i(0)$$

という二つの潜在的結果を最初に定義します．ここで $Y_i(1)$ は処置を受けた場合の結果，$Y_i(0)$ は処置を受けなかった場合の結果でした．

観測されるのは

$$Y_i = Y_i(D_i)$$

のみであり，もう一方は反実仮想として未観測です．この枠組みにおいて個体処置効果は

$$Y_i(1) - Y_i(0)$$

と定義され，平均処置効果（ATE）は

$$\mathrm{ATE} = \mathbb{E}[Y(1) - Y(0)]$$

と定義されます（本文第 5 章参照）．

潜在的結果モデルではこれらの量は「定義」であり，どのような生成プロセスがそれを生み出すかは明示されません．

構造的因果モデル（SCM）

構造的因果モデルでは，変数は構造方程式によって生成されます．

$$X = f_X(U_X), \qquad Y = f_Y(X, U_Y)$$

ここで U_X, U_Y は外生変数です．反実仮想は，外生変数 u を固定したまま，構造方程式を介入によって改変することで定義されます．

たとえば $X = x$ と介入した場合，

$$Y_x(u) = f_Y(x, u_Y)$$

と定義されます．このように構造的因果モデルにおいては，反実仮想は構造方程式から導出される量です．

両者の数学的関係

構造的因果モデルが与えられれば，潜在的結果は自然に定義できます．

$$Y(1) = Y_{x=1}(U), \qquad Y(0) = Y_{x=0}(U)$$

したがって，

$$\mathrm{ATE} = \mathbb{E}[Y(1) - Y(0)] = \mathbb{E}[Y_1(U) - Y_0(U)]$$

となり，両モデルの平均因果効果は一致します．

しかし逆は一般には成立しません．すなわち，潜在的結果の存在だけから構造方程式や因果ダイアグラムを一意的に導出することはできません．

以上の比較を一覧にまとめると，両者の主要概念は表 8 のように対応します．同じ用語であっても，潜在的結果モデルでは「定義として置く」ものが多く，SCM では「構造方程式や DAG から導出される」ものが多い，という違いがあります．

表 8　潜在的結果モデルと SCM における主要概念の対比

概念	潜在的結果モデル	構造的因果モデル（SCM）
反実仮想	定義として導入された未観測の潜在的結果 $Y(x)$	外生変数 u を固定し構造方程式を改変して導出される $Y_x(u)$
介入	明示的演算子は持たず，処置割当として暗黙的に扱う	$do(X = x)$ により構造方程式を書き換える明示的操作
個体処置効果	$Y_i(1) - Y_i(0)$	$Y_1(u) - Y_0(u)$（同一の外生変数 u に対する差）
平均処置効果	$\mathbb{E}[Y(1) - Y(0)]$（定義）	$\mathbb{E}[Y_1 - Y_0]$（構造方程式と U の分布から計算）
条件付き独立	強い無視可能性などを仮定として置く	DAG の構造（パスのブロックなど）から導出する
交絡変数	無視可能性を成り立たなくする変数	DAG 上で処置と結果の共通原因
一致性	$Y_i = Y_i(D_i)$ を公理として置く	構造方程式から自動的に従う
外生変数	暗黙的に潜在的結果に吸収される	U として明示的に分離

まとめると，潜在的結果モデルは因果効果を定義するための枠組みであり，構造的因果モデルは因果を生成するプロセスを記述する枠組みです．構造的因果モデルは潜在的結果を内包しますが，潜在的結果モデルは必ずしも構造を特定しません．両者は対立的というよりも，抽象度が異なる一連のシステムと理解するのが適切です．

12　第 12 章に対応する補足資料

12.1　$pR < 1$ の領域における相対的剥奪モデルのパラメータリカバリー

ここでは，本文第 12 章で導入した相対的剥奪モデル（Boudon モデル）のうち，$pR < 1$ の線形な領域を取り上げます．この領域の観察データから構造パラメータを推定する手続きと，シミュレーションによるパラメータリカバリーの考え方を示します．したがって，ここでの検証対象は閾値 $pR = 1$ をまたぐ区分線形モデル全体ではありません．

はじめに推定の対象と識別の枠組みを確認します．本文の構造的因果モデルを再掲します（$pR < 1$ の領域）．

$$
\begin{aligned}
P &= U_P, & U_P &\sim \mathrm{Uniform}(0,1) \\
X &= RP + U_X, & U_X &\sim N(0, \sigma_X^2) \\
S &= X - P + U_S, & U_S &\sim N(0, \sigma_S^2)
\end{aligned}
$$

ここで U_P, U_X, U_S は互いに独立な外生変数です．推定したいパラメータは利益率 R と外生変数の分散 σ_X^2, σ_S^2 です．

このモデルは $pR < 1$ の領域では線形なので，最小二乗法で各パラメータが識別できます．$X = RP + U_X$ から

$$
\hat{R} = \frac{\widehat{\mathrm{Cov}}(P, X)}{\widehat{V}(P)}, \qquad \hat{\sigma}_X^2 = \widehat{V}(X - \hat{R}P)
$$

が得られます．$S = X - P + U_S$ は $X - P$ と S の差として U_S が直接観察できる構造なので，

$$
\hat{\sigma}_S^2 = \widehat{V}(S - (X - P))
$$

となります．$pR < 1$ の領域の観測が利用でき，上の線形モデルと外生変数に関する仮定が成り立つとき，これらは一致推定量となり，標本サイズ $n \to \infty$ で真値に確率収束します．

パラメータリカバリーとは，真のパラメータを与えて構造的因果モデルからデータを生成し，そのデータから上記の手続きでパラメータを推定して，推定値が真値を正確に回復できるかを確認するシミュレーション実験です．モデルが識別可能であり，かつ推定手続きが妥当であれば，標本サイズを十分に大きくしたとき推定値の平均は真値に近づきます．

たとえば真のパラメータを $R = 2$, $\sigma_X^2 = \sigma_S^2 = 0.0025$ と固定し，P を $pR < 1$ となる範囲に限定して，標本サイズ $n = 1000$ のデータを多数回生成します．上記の推定式を適用すると，推定値の平均は真値とほぼ一致することが確認できます．以下に検証用の R コードを示します．

```
set.seed(123)
R_true <- 2; sigmaX <- 0.05; sigmaS <- 0.05
n <- 1000; reps <- 1000
estimates <- replicate(reps, {
```

```
  P  <- runif(n, 0, 1/R_true)       # PR<1 の領域に限定
  Ux <- rnorm(n, 0, sigmaX)
  Us <- rnorm(n, 0, sigmaS)
  X  <- R_true * P + Ux
  S  <- (X - P) + Us
  R_hat   <- cov(P, X) / var(P)
  sX2_hat <- var(X - R_hat * P)
  sS2_hat <- var(S - (X - P))
  c(R_hat, sX2_hat, sS2_hat)
})
rowMeans(estimates)         # 真値 c(2, 0.0025, 0.0025) に近いはず
apply(estimates, 1, sd)     # 推定値の標準偏差
```

$pR \geq 1$ の領域では X は P と独立に決まる（$X = 1 + U_X$）ため，R 自体は $P \in [1/R, 1]$ のデータだけからは識別できません．したがって，R を識別するには $pR < 1$ の領域（少なくとも一部）の観測が必要です．実証研究では，処置変数 P の分布が十分広い範囲をカバーしていることが識別の前提となります．

最後に，実証データへ応用する際の注意を述べます．パラメータリカバリーは「もし観測データがモデルに従って生成されているなら，モデルの構造パラメータは取り出せる」ことを示すだけで，「実際の社会現象がモデルに従っている」ことを保証するわけではありません．ここで示した推定手続きを実証データに適用する際は，モデルが対象とする現象を適切に表現しているか，外生変数の独立性が成り立つか，処置変数 P の分布が識別に十分かなど，モデルの妥当性を別途検証する必要があります．Berger and Diekmann (2015) や Otten (2023) など，相対的剥奪モデルの実証研究は，こうした妥当性を多面的に検討しています．

参考文献

[1] Angrist, J. D. and Pischke, J.-S. (2009), *Mostly Harmless Econometrics: An Empiricist's Companion*, Princeton University Press.

[2] Angrist, J. D., & Krueger, A. B. (1991). Does compulsory school attendance affect schooling and earnings? *Quarterly Journal of Economics*, 106(4), 979–1014.

[3] Balke, A., & Pearl, J. (1997). Bounds on treatment effects from studies with

imperfect compliance. *Journal of the American Statistical Association*, 92(439), 1171–1176.

[4] Berger, J., & Diekmann, A. (2015). The logic of relative frustration: Boudon's competition model and experimental evidence. *European Sociological Review*, 31(6), 725–737.

[5] Bound, J., Jaeger, D. A., & Baker, R. M. (1995). Problems with instrumental variables estimation when the correlation between the instruments and the endogenous explanatory variable is weak. *Journal of the American Statistical Association*, 90(430), 443–450.

[6] Imbens, G. W., & Angrist, J. D. (1994). Identification and estimation of local average treatment effects. *Econometrica*, 62(2), 467–475.

[7] Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press.

[8] 宮川雅巳. (2004).『統計的因果推論——回帰分析の新しい枠組み』朝倉書店.

[9] Otten, K. (2023). The logic of relative frustration revisited: Theoretical revision of Boudon's competition model and experimental evidence. *European Sociological Review*, 39(4), 630–645.

[10] Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.

[11] Rosenbaum, P. R., & Rubin, D. B. (1983). The central role of the propensity score in observational studies for causal effects. *Biometrika*, 70(1), 41–55.

[12] Robins, J. M., Rotnitzky, A., & Zhao, L. P. (1994). Estimation of regression coefficients when some regressors are not always observed. *Journal of the American Statistical Association*, 89(427), 846–866.

[13] 竹村彰通. (2020).『現代数理統計学（新装改訂版)』学術図書出版社.

[14] Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data* (2nd ed.). MIT Press.

[15] Wright, P. G. (1928). *The Tariff on Animal and Vegetable Oils*. Macmillan. (付録が最初期の IV アイディアを含む)